

TrustForge Hermes | 商業化 AI Agent 產品講稿

8 頁 | 目標 6 分鐘 | 產品 / 工程 / 金融企業語氣

說法邊界：TrustForge 已有完整的 runtime、Trust Kernel、前後端產品面、升級治理與 training backend；目前每次 run 會沉澱 learning event，訓練資料需等 T+1/T+7/T+14 outcome 成熟後顯式產生 candidate，並非每次分析立即自動重訓或自動上線。正式部署拓樸為 EC2 + nginx，非 App Runner。

第1頁 | 0:00-0:40

Product thesis：把會回答的 Agent 變成可治理的判斷系統

各位評審好，我們是 Team 11 中再參與。今天不把 TrustForge 當成一次性的競賽 demo，而是把它當成一個可以被金融資訊團隊採用的產品：TrustForge Hermes，evidence-native decision intelligence agent。

它的核心不是再做一個聊天模型，而是把多源資料、可驗證主張、deterministic trust reasoning、模型協作與 audit trail 組成同一個 runtime。使用者拿到的不只是答案，而是一筆可以追問、重播、稽核、回滾的 decision record。

講者提示：開場不要先講評分標準；先建立產品定位。

Product surface : 同一核心服務研究、營運與企業整合

在產品表面，Hermes Workspace 提供 Analyze、Compare、History、Source Status、Whale Activity 和 Evidence Trail。研究者可以從一個問題開始，看到多源結果、反方證據、限制、執行旅程與可下載 artifacts。

對營運與治理人員，系統還有 Training Status、Budget、Carbon、Module Telemetry、Upgrade Queue、Memory、AgentCore 與 admin audit。對外則透過 API、comparison snapshot、analysis journey、Final Report、Evidence List 和 Execution Log 接入既有 workflow。

講者提示：說明這不是單一頁面，而是研究面、控制面、整合面的完整產品。

Runtime architecture : 有界、可觀測、可回復的 Agent

Hermes runtime 從 Ingestion 開始，讀取 OHLCV、新聞、社群、監管、鏈上、Whale、HOYA BIT 與其他市場資料；接著進入 reasoning pipeline，完成 claim extraction、stance、deduplication、corroboration、Trust Kernel 與 uncertainty；最後交付 report、evidence、execution log、snapshot 和 API response。

這個 Agent 有固定 tool registry、來源範圍、政策、預算與時間上限。Memory plane 保存 run、artifact、evidence、learning event 和 replay history；policy plane 記錄 source、analysis、report、evaluation、improvement 的實際消費者。遇到逾時、資料不足、權限錯誤或模型異常，系統不是硬湊答案，而是 degraded、abstain 或 fail-closed。

Trust Kernel：把資訊品質變成可計算的 decision state

金融場景不能只相信模型的語氣。TrustForge 的 Evidence contract 要求每筆資料帶 source、fetched_at、content_reference、related_claim，以及可供回源的 URL、endpoint、query 或檔案資訊。

Trust Kernel 以 deterministic logic 計算來源信譽、freshness half-life、獨立交叉佐證、stance 與 manipulation risk，再輸出 trust score、calibrated confidence、direction、reason codes、independent source count 和 abstain 狀態。canonical source identity、claim grouping 與 union-find 會把同稿轉載去重，避免重複計票。

矛盾不會被平均掉。contrarian evidence、Conflict Ledger、could_flip 與 stance pair 會保留分歧；Asset Intrinsic、Peer Metrics、multi-angle 與 Whale history 則把單一分數放回可解釋的市場脈絡。

Learning system：我們訓練的是信心校準與來源可靠度

我們不直接採用通用模型的 confidence，因為通用模型不知道 TrustForge 的 Evidence contract，也不知道某一類來源在這個市場、這個時間尺度上到底可靠不可靠。每一次 analysis run 都會留下 report、evidence、execution log、raw confidence 與 learning event；但立即拿去重訓會造成 label leakage，所以我們等待 T+1、T+7、T+14 的 OHLCV 與 direction outcome 成熟。

成熟資料會進入嚴格 JSONL training contract，經 schema、finite-value、split、資料完整性與 calibrator gate 檢查，再訓練 Isotonic Regression 或 logistic calibrator，計算 ECE、holdout 與 improvement，產生帶 artifact hash 的 candidate proposal。

ModelHub 是版本、指標、request、artifact provenance 與 lifecycle 的治理介面；SageMaker AI 是 AWS Training Job、S3 dataset 和 artifact 的執行後端。訓練完成仍是 candidate，不是 production；automatic_apply=false、requires_human_approval=true。

講者提示：這裡主動講清楚「資料閉環」與「立即自動訓練」的差別，可信度比誇大自動化更重要。

Control plane : 升級能力與安全邊界一起產品化

Hermes 的 upgrade control 把 provider、policy、model、calibrator、RAG index 和 reranker 都視為 candidate。候選先在 sandbox 量測，經 diagnostics、adversarial review、artifact integrity、reviewer gate，最後才有人工 activation。Trust Kernel 仍是 reviewed code release，不會被 outer skill 直接改寫。

企業級可靠性也在同一層：formal run、multi-angle batch、DynamoDB 或 SQLite lease、atomic reconcile、retry、rollback receipt 和 idempotency key，避免重複執行與半完成狀態。IAM least privilege、SSM、token gate、rate limit、budget reservation、CloudWatch、carbon ledger、secret scan 和 release gate 則負責安全、成本與可觀測性。

Deployment : 現有 AWS 生產拓樸與整合邊界

現有公開拓樸是 EC2 t3.micro 上的 nginx，對外提供 80/443；Python API 收斂在 127.0.0.1:8080。React/Vite frontend 由 nginx 提供，API 再進入 TrustForge pipeline。Amazon Bedrock 是唯一 LLM 入口，S3 保存部署與 artifact，IAM Instance Role、SSM Session Manager 與 CloudWatch 支援最小權限和無 SSH key 的運維。

App Runner 並不是目前已部署的入口；它是未採用的舊願景。產品設計保留 provider、storage、memory、model backend 的介面，所以未來可以替換部署或模型，但現在的商業化敘事必須以已驗證的 EC2 + nginx 拓樸為準。

對外可交付的不是畫面截圖，而是同一個 run_id 串起 Final Report、Evidence List、Execution Log、Source/Config、manifest 與 SHA-256。

Commercial outcome：把信任與治理變成可整合能力

對金融與資料團隊，TrustForge 把分散市場訊號轉成可查證的 decision record；confidence、limits、could_flip 和 contrarian evidence 讓風險溝通有共同語言。對產品與平台團隊，provider、policy、memory、retrieval 和 calibrator 都能替換，model upgrade 有 candidate、review、rollback 和 audit。

這就是我們與一般 Agent 的差異：Agent 可以執行動作，但金融企業還需要知道它依據什麼、誰批准它、成本是多少、資料是否過期，以及出錯時能不能回復。TrustForge Hermes 的產品答案是 evidence-native、policy-aware、replayable、reversible。

從會回答的 AI，走向值得託付的 AI Agent。謝謝各位。

講者提示：最後一句放慢；不要再補充未驗證的性能或自動化承諾。